



Predicción de Precios de Vivienda

Gabriel Mejía Ruiz
David Alejandro Romero Muñoz

Proyecto Final

Los datos: Ames Housing



880

filas de
entrenamiento

220

filas de
prueba (test)

~80

variables
predictoras

1

variable objetivo:
SalePrice

El reto de un dataset pequeño

- Con solo 880 filas de entrenamiento, la validación cruzada tiene mucha variabilidad: medimos que un mismo modelo puede dar entre 18,000 y 30,000 de error según que filas caen en cada partición.
- Esto obliga a usar validación cruzada repetida (múltiples particiones) para tomar decisiones confiables sobre el modelo, en lugar de confiar en una sola corrida.

Variables clave del dataset



Tamaño y distribución

Area habitable, área del sótano, numero de habitaciones y baños, área total del lote.



Calidad y condición

Calificación general de la casa, calidad de cocina, del exterior, del sótano y del garaje.



Ubicación

Vecindario, zonificación, tipo de calle y configuración del lote.



Antigüedad

Año de construcción, año de remodelación, año de venta - la edad de la casa.

Metodología: el pipeline de trabajo



Limpieza

Detección y manejo de valores atípicos (outliers) documentados en el dataset.



Imputación

Tratamiento de datos faltantes: por categoría, por mediana, por vecindario.



Ingeniería de variables

Creación de variables nuevas: áreas totales, antigüedad, interacciones calidad x tamaño.



Codificación

Transformar variables categóricas en numéricas (frequency-encoding y one-hot encoding).



Modelado y validación

Entrenamiento de múltiples modelos con validación cruzada robusta y combinación (ensamble).

Modelos evaluados



Ridge / Lasso / ElasticNet

Regresión lineal regularizada



Random Forest

Ensamble de arboles de decisión



Gradient Boosting

Árboles que corrigen errores de forma iterativa



SVR (Support Vector Regression)

Método clásico basado en márgenes



XGBoost

Boosting optimizado, muy usado en competencias



Ensamble final (blend)

Combinación ponderada de los mejores modelos

Validación: ¿Cómo supimos que funcionaba?



Validación cruzada (K-Fold)

Se divide el train en partes; se entrena con unas y se prueba con las otras, rotando. Da una medida honesta del error antes de usar el test real.



Validación cruzada repetida


Repetimos el K-Fold varias veces con distintas particiones para reducir el ruido de una sola corrida — clave en un dataset chico.



Selección de pesos del ensamble

El peso de cada modelo en la combinación final se elige minimizando el error de validación cruzada, no a mano.

Resultados: evolución del score



-13.4%

de mejora total
en el error (RMSE)

- Cada mejora fue validada con evidencia (cross-validation) antes de subirse.
- Los saltos mas grandes vinieron de mejorar la representación de los datos, no de un solo modelo.
- Se priorizó la honestidad del proceso sobre perseguir un numero específico.

Conclusiones



Con pocos datos, el CV es ruidoso

Un solo split de validación cruzada puede variar miles de dólares de error solo por azar. Hay que validar con múltiples particiones antes de confiar en una mejora.



La representación de los datos importa tanto como el modelo

Cambiar de frequency-encoding a one-hot encoding tuvo mas impacto que cambiar de modelo.



Combinar enfoques distintos, ayuda

Dos pipelines que se equivocan de forma distinta, al promediarse, reducen el error total.